

Convex Optimization-Homework 3

Hugo Blanc

November 2021

1 Derive the dual problem of LASSO

Le problème LASSO se présente sous la forme suivante :

$$\text{minimize } \frac{1}{2} \|Xw - y\|_2^2 + \lambda \|w\|_1 \quad (\text{LASSO})$$

, tel que $w \in \mathbb{R}^d$ est la variable sur laquelle on minimise, les données sont $X = (x_1^T, x_2^T, \dots, x_n^T) \in \mathbb{R}^{n \times d}$, $y = (y_1, \dots, y_n) \in \mathbb{R}^n$ et $\lambda > 0$ est un paramètre de régularisation.

Pour déterminer le problème dual de ce problème (LASSO), on commence par introduire une variable $z = Xw - y$ et on réécrit le problème sous la forme suivante :

$$\begin{cases} \text{minimize } \frac{1}{2} \|z\|_2^2 + \lambda \|w\|_1 \\ \text{tel que } z = Xw - y \end{cases} \quad (1)$$

Par la suite, on écrit le Lagrangien du problème précédent :

$$\begin{aligned} L(w, z, \nu) &= \frac{1}{2} \|z\|_2^2 + \lambda \|w\|_1 + \nu^T (Xw - y - z) \\ &= \frac{1}{2} \|z\|_2^2 - \nu^T z + \lambda \|w\|_1 + \nu^T Xw - \nu^T y \end{aligned}$$

Ensuite, la fonction duale de Lagrange est donc :

$$\begin{aligned} g(\nu) &= \inf_{w, z} L(w, z, \nu) \\ &= \inf_z \left\{ \frac{1}{2} \|z\|_2^2 - \nu^T z \right\} + \inf_w \{ \lambda \|w\|_1 + \nu^T Xw \} - \nu^T y \\ &= - \sup_z \left\{ \nu^T z - \frac{1}{2} \|z\|_2^2 \right\} - \sup_w \{ -(X^T \nu)^T w - \lambda \|w\|_1 \} - \nu^T y \end{aligned}$$

Aussi, on retrouve des expressions proche de celles étudiés durant le deuxième devoir. Il nous faut en effet calculer les fonctions conjuguées des deux fonctions suivantes :

$$z \mapsto \frac{1}{2} \|z\|_2^2 \quad w \mapsto \lambda \|w\|_1$$

Fonction conjuguée de $z \mapsto \frac{1}{2} \|z\|_2^2$:

Soit $\nu \in \mathbb{R}^n$, on calcule l'expression de la fonction conjuguée évaluée en ν :

On note $f : z \mapsto \nu^T z - \frac{1}{2} \|z\|_2^2$, cette fonction est de classe \mathcal{C}^∞ et :

$$\begin{aligned}\nabla f(z) &= \nu - z \\ \nabla^2 f(z) &= -I_n \leq 0\end{aligned}$$

Donc, la fonction f est concave, ainsi tout point critique de f maximisera f .

Ainsi, $z = \nu$ maximise la fonction f et donc on en déduit que :

$$\sup_z \{\nu^T z - \frac{1}{2} \|z\|_2^2\} = \frac{1}{2} \|\nu\|_2^2$$

Fonction conjuguée de $g : w \mapsto \lambda \|w\|_1$:

Soit $x \in \mathbb{R}^d$, et soit $w \in \mathbb{R}^d$ avec $w \neq 0$,

$$\begin{aligned}(x, w) - \lambda \|w\|_1 &= ((x, \frac{w}{\|w\|_1}) - \lambda) \|w\|_1 \\ &\leq \left(\sup_{u, \|u\|_1=1} \{(x, u)\} - \lambda \right) \|w\|_1\end{aligned}$$

On distingue alors deux cas :

- Si $\sup_{u, \|u\|_1=1} \{(x, u)\} \leq \lambda$:
Dans ce cas, on a :

$$(x, w) - \lambda \|w\|_1 \leq 0$$

De plus, en $w = 0$ on a $(x, w) - \lambda \|w\|_1 = 0$.

Aussi, la fonction conjuguée vaut 0 en x si $\sup_{u, \|u\|_1=1} \{(x, u)\} \leq \lambda$.

- Si $\sup_{u, \|u\|_1=1} \{(x, u)\} > \lambda$:

Dans ce cas, si on prend w_* tel que $(x, \frac{w_*}{\|w_*\|_1}) > \lambda$ et que l'on pose $w_\alpha = \alpha w_*$, on aura finalement :

$$(x, w_\alpha) - \lambda \|w_\alpha\|_1 = ((x, \frac{w_\alpha}{\|w_\alpha\|_1}) - \lambda) \|w_\alpha\|_1 \xrightarrow{\alpha \rightarrow +\infty} +\infty$$

Aussi, on obtient que la fonction conjuguée vaut $+\infty$ en x si $\sup_{u, \|u\|_1=1} \{(x, u)\} > \lambda$

Par ailleurs, on peut remarquer que $\sup_{u, \|u\|_1=1} \{(x, u)\} = \|x\|_\infty$.

Ainsi, la fonction duale g^* est la fonction indicatrice de la boule de rayon λ pour $\|\cdot\|_\infty$.

Aussi, le problème dual de (LASSO) est :

$$\begin{cases} \sup_\nu -\frac{1}{2} \|\nu\|_2^2 - \nu^T y \\ \text{tel que } \|X^T \nu\|_\infty \leq \lambda \end{cases} \quad (2)$$

De plus, la contrainte :

$$\|X^T \nu\|_\infty \leq \lambda \iff \begin{pmatrix} (X^T \nu)_1 \\ (X^T \nu)_2 \\ \vdots \\ (X^T \nu)_d \\ -(X^T \nu)_1 \\ -(X^T \nu)_2 \\ \vdots \\ -(X^T \nu)_d \end{pmatrix} \leq \begin{pmatrix} \lambda \\ \vdots \\ \lambda \end{pmatrix}$$

Aussi, le dual du problème (LASSO) s'écrit sous la forme :

$$\begin{cases} \text{minimize}_v v^T Q v + p^T v \\ \text{tel que } A v \leq b \end{cases} \quad (3)$$

où on a $Q = \frac{1}{2} I_n \geq 0$, $p = y$, $A = \begin{pmatrix} X^T \\ -X^T \end{pmatrix}$ et enfin $b = \begin{pmatrix} \lambda \\ \vdots \\ \lambda \end{pmatrix}$

2 Implémentation

Voir le code pour l'implémentation de l'algorithme de résolution demandé.

Pour résoudre le dual algorithmiquement, on a utilisé la méthode barrière algorithmique associé à la résolution du pas de centrage qui permet de trouver un pas d'amélioration à chaque itération. Le problème du pas de centrage est résolu en utilisant la méthode de Newton sur le problème intermédiaire.

3 Analyse des résultats

Si on revient brièvement au problème initial, on remarque que le problème primal (où l'on a introduit la contrainte d'égalité) est un problème convexe, et qu'il est réalisable. Ainsi, la contrainte de qualification de Slater est vérifiée et il y a forte dualité.

Soit v_* solution du dual et z_* , w_* solution du primal on obtient en utilisant les conditions de Karush-Kuhn-Tucker, sachant que le lagrangien L est différentiable par rapport à z , que le gradient partiel de L par rapport à z s'annule en (v_*, z_*, w_*) , or :

$$\nabla_z L(z) = v - z \quad (4)$$

Aussi, on en déduit que $v_* = z_*$. Par ailleurs, l'optimum est un point réalisable du primal donc :

$$z_* = X w_* - y \quad (5)$$

Et finalement, on obtient l'expression de w_* dépendant v_* ce qui va nous permettre de répondre à la question :

$$v_* = Xw_* - y \quad (6)$$

Tout d'abord on génère une matrice aléatoire X et on prend $\lambda = 10$, puis on affiche le critère de précision ainsi que l'écart à la solution optimale (obtenue) pour chaque itération de l'algorithme barrière.




FIGURE 1 – Affichage des résultats de précision pour $\lambda = 10$ (et $\mu=15$)

Aussi, on obtient qu'il y a ici 9 itérations de la méthode barrière logarithmique avant arrêt et convergence. De plus, le critère de précision est bien vérifié.

Désormais, on répète l'expérience pour les valeurs suivantes de $\mu = [2, 7, 15, 50, 100, 200]$ afin d'observer l'influence de ce paramètre.




FIGURE 2 – Affichage des résultats de précision pour $\lambda = 10$ (et $\mu=15$)

Globalement, on observe que lorsque μ augmente, il y a de moins en moins d'itérations dans l'algorithme barrière comme l'on pouvait s'attendre théoriquement. En effet, le nombre maximal d'itérations est ici de 24 itérations pour $\mu = 2$. Par ailleurs, on sait que lorsque μ augmente le nombre d'itérations pour la résolution du problème intermédiaire par la méthode de Newton augmente. C'est d'ailleurs ce qui a été vérifié (voir ci-après) :




FIGURE 3 – Nombre moyen d'itérations de la méthode de Newton en fonction de μ

Ainsi, il faudra faire un compromis sur la valeur de μ . On peut ici sélectionner $\mu = 15$ ou $\mu = 50$ qui auront ici un nombre d'itérations total faible.

Aussi, il était demandé de vérifier l'impact de μ sur la solution du problème primal w et après vérification μ n'a pas d'impact sur la valeur de w . En effet, on retrouve à chaque fois la même valeur de w .